# CODE

Go through the TRONCO PICNIC R vignette and identify the parts that download the COADREAD data.

Note that PICNIC uses different tools to get to the data.

Nelle vignette del package TRONCO, utilizzato all'interno della pipeline PICNIC, il download e la gestione dei dati COADREAD avvengono nella sezione **Loading data**.

In particolare, TRONCO supporta più modalità di accesso ai dati:

1. **Dataset COADREAD di esempio già inclusi nel package**, come crc_maf, crc_gistic e crc_plain, che rappresentano versioni ridotte dei dati TCGA COADREAD e vengono usati per scopi dimostrativi:

## 3 Loading data

```
library(TRONCO)
data(aCML)
data(crc_maf)
data(crc_gistic)
data(crc_plain)
```

2. **Importazione diretta di file TCGA** in formato MAF e GISTIC tramite le funzioni import.MAF e import.GISTIC, permettendo l'analisi di dati reali scaricati localmente.

## 3.1 Mutations annotated in a MAF format

We use the function `import.MAF` to import a dataset in MAF format, in this case the following TCGA dataset

```
head(crc_maf[, 1:10])

##      Hugo_Symbol Entrez_Gene_Id       Center NCBI_Build Chromosome Start_position
## 27          TP53           7157 hgsc.bcm.edu         36         17        7519131
## 246        FBXW7          55294 hgsc.bcm.edu         36          4      153466817
## 623          APC            324 hgsc.bcm.edu         36          5      112192485
## 649         TP53           7157 hgsc.bcm.edu         36         17        7518937
## 928        FBXW7          55294 hgsc.bcm.edu         36          4      153468834
## 1390        TP53           7157 hgsc.bcm.edu         36         17        7517864
##      End_position Strand Variant_Classification Variant_Type
## 27        7519131      +      Missense_Mutation          SNP
## 246     153466817      +      Nonsense_Mutation          SNP
## 623     112192485      +      Nonsense_Mutation          SNP
## 649       7518937      +      Nonsense_Mutation          SNP
## 928     153468834      +      Missense_Mutation          SNP
## 1390      7517864      +      Missense_Mutation          SNP
```

## 3.2 Copy Number Variants annotated in the GISTIC format

We use the function `import.GISTIC` to import a dataset in GISTIC format, in this case from

```
crc_gistic

##               NRAS CTNNB1 FBXW7 APC KRAS TP53
## TCGA-A6-2670   -1      0     0  -1    1   -1
## TCGA-A6-2672    0      0     0   0    0    0
## TCGA-A6-2674    0      0     0   0    0    0
## TCGA-A6-2676    0      0     0   0    0    0
## TCGA-A6-2677    0      0     0   0    0   -1
## TCGA-A6-2678    0      0     0   0    0   -1
## TCGA-A6-2683   -1     -1    -1  -1    0   -1
## TCGA-A6-3807    0     -1     0   0   -1   -1
## TCGA-AA-3516    0      0     0   0    0    0
```

3. **Download diretto dal cBioPortal**, effettuato tramite l'interfaccia cbio.query, che consente a PICNIC di interrogare studi TCGA (incluso COADREAD) selezionando geni, profili genomici e dataset specifici:

```
data = cbio.query(
    genes=c('TP53', 'KRAS', 'PIK3CA'),
    cbio.study = 'luad_tcga_pub',
    cbio.dataset = 'luad_tcga_pub_cnaseq',
    cbio.profile = 'luad_tcga_pub_mutations')
```

Questo mostra come PICNIC utilizzi strumenti differenti (dataset interni, file TCGA e cBioPortal) per ottenere e integrare i dati genomici necessari all'inferenza dei modelli di progressione tumorale.

(link al documento che mi è servito per fare l'esercizio:

https://ftp.openbsd.dk/bioconductor-releases/3.14/bioc/vignettes/TRONCO/inst/doc/vignette.pdf)

# REVIEW

## Compare the progression graphs obtained with the TRONCO/PICNIC code for

- MSS
- MSI-high
- MSI-low

Nel caso **MSS (Microsatellite Stable)**, i grafi risultano in genere più **lineari e gerarchici**.

Questo è coerente con un modello di progressione classico associato all'instabilità cromosomica (CIN), in cui le alterazioni genetiche tendono ad accumularsi secondo un ordine relativamente ben definito, con pochi rami alternativi. La progressione appare quindi più prevedibile e meno eterogenea dal punto di vista clonale.

Al contrario, nei tumori **MSI-high**, caratterizzati da difetti nei meccanismi di DNA mismatch repair e da un elevato carico mutazionale, i grafi di progressione sono **più complessi e ramificati**.

In questo caso TRONCO/PICNIC inferisce molteplici percorsi evolutivi alternativi, indicando una forte eterogeneità clonale e l'assenza di una singola sequenza dominante di eventi genetici. Questo riflette una dinamica evolutiva più instabile e meno vincolata a una progressione lineare.

Il sottotipo **MSI-low** mostra un comportamento **intermedio** tra MSS e MSI-high. I grafi presentano una struttura più articolata rispetto a MSS, ma meno complessa rispetto a MSI-high, suggerendo un livello moderato di

eterogeneità e una progressione che combina caratteristiche di entrambi i modelli.

Nel complesso, il confronto tra i grafi evidenzia come lo stato di instabilità dei microsatelliti influenzi in modo significativo la struttura dei modelli di progressione tumorale: a maggiore instabilità genomica corrispondono grafi più ramificati e una maggiore diversità di percorsi evolutivi, in accordo con quanto discusso nelle lezioni di evoluzione del cancro e modellazione computazionale.

# CHECK

- List the three main domains the are currently considered to be the largest grouping of life forms on the planet

- According the the LUCA assumption, did the three domain emerge at the same time? If not, which did last?

- What problem of Darwin's theory of natural selection was solved by the "Modern Synthesis" by Haldane, Fischer, Wright and others?

1) Sono tre:

- Bacteria (Batteri) che comprendono la maggior parte degli organismi procarioti;
- Archaea (Archea), ovvero organismi procarioti distinti dai batteri per caratteristiche genetiche e biochimiche;
- Eukarya (Eucarioti) che includono tutti gli organismi eucarioti, come animali, piante, funghi e protisti;

2) No, i tre domini non sono emersi contemporaneamente nella loro forma attuale, ma si sono differenziati progressivamente a partire da LUCA.

In base ai modelli evolutivi più accreditati, il dominio Eukarya è considerato l'ultimo a emergere, probabilmente a partire da un lignaggio archaeale, attraverso eventi evolutivi complessi come l'endosimbiosi che ha portato alla formazione dei mitocondri.

Quindi, l'ultimo (in questo senso) è Eukarya.

3) Darwin spiegava bene la selezione naturale, ma non chiariva come le variazioni venissero generate e trasmesse alle generazioni successive.

La “Modern Synthesis“, sviluppata da studiosi come Fisher, Haldane e Wright, ha risolto questo problema integrando:

- la genetica mendeliana;
- la genetica delle popolazioni;
- la selezione naturale;

In questo modo è stato dimostrato che la variazione genetica nasce da mutazioni e ricombinazione, viene ereditata in modo discreto e evolve attraverso cambiamenti nelle frequenze alleliche guidati da selezione naturale, deriva genetica e altri processi evolutivi.

# CHECK

- List the major kinds of algorithms that compute phylogenies of data

- List the prototypical steps of “distance-based methods”

- Construct the nearest neighbor tree starting from the data

  ```
  {{4, 0}, {-2, 1}, {2, -2}, {-3, -1}, {3, 2}}
  ```

  Please work through the steps

1) I principali approcci algoritmici per la ricostruzione di alberi filogenetici possono essere suddivisi in tre grandi categorie:

- Metodi basati sulla distanza (distance-based methods) che ricostruiscono la filogenia a partire da una matrice di distanze tra coppie di elementi.
- Metodi basati sul carattere (character-based methods) che tilizzano direttamente i caratteri osservati (per esempio: nucleotidi e mutazioni) e cercano l’albero che meglio li spiega.
- Metodi probabilistici (ovvero bayesiani) che modellano esplicitamente il processo evolutivo e stimano una distribuzione di probabilità sugli alberi possibili.

2) I metodi distance-based seguono una procedura seguente:

- Rappresentazione dei dati, dove gli oggetti (specie, campioni, cellule e ecc) sono rappresentati come vettori di caratteristiche.
- Calcolo della matrice delle distanze dove si calcola una distanza pairwise (per esempio: euclidea, Hamming, genetica) tra tutte le coppie di elementi.

- Costruzione iterativa dell'albero dove si identificano gli elementi (o cluster) più vicini e li si unisce progressivamente.
- Aggiornamento delle distanze dove dopo ogni fusione, la matrice delle distanze viene aggiornata.
- Terminazione dove il processo continua fino a ottenere un singolo albero che include tutti gli elementi.

3) Siccome sono dati cinque punti nello spazio bidimensionale, li indichiamo come:

- A = (4, 0)
- B = (−2, 1)
- C = (2, −2)
- D = (−3, −1)
- E = (3, 2)

Successivamente si calcola la distanza euclidea tra tutte le coppie di punti.

Si ottiene che le distanze minime risultano essere:

- d(A, E) circa 2.24
- d(B, D) circa 2.24

Queste coppie rappresentano i nearest neighbors, che riflettono la struttura geometrica dei dati, raggruppando inizialmente i punti più simili (più vicini nello spazio) e costruendo progressivamente una gerarchia.

A questo punto si può scegliere una delle coppie più vicine, unendo A ed E in un primo cluster C(AE) = {A, E}.

Ora si aggiornano le distanze, avendo cluster C(AE), B, C e D. La coppia più vicina viene fusa di nuovo, ottenendo un nuovo cluster C(BD) = {B, D}.

Si ripete il processo, aggiornando le distanze tra i due cluster: C(AE) e C(BD), e C. Alla fine si ottiene un unico albero che include tutti i punti.

# REVIEW

## Check the **TRaIT** vignettes in the TRONCO package

TRaIT è integrato nel pacchetto TRONCO e la sua documentazione è accessibile tramite le vignette ufficiali del pacchetto su Bioconductor.

Si può consultare articoli come quelli su e-learning:

biorXiv TRAIT Ramazzotti 132183.full.pdf e TRAIT paper.pdf

Queste vignette, insieme agli articoli scientifici associati, descrivono il framework TRaIT (temporal order of mutational events) e i relativi algoritmi per l'inferenza di grafi di progressione tumorale a partire da dati multi-sample (multi-region e single-cell). Infatti, questi dati permettono di osservare eterogeneità intra-tumorale e cloni diversi.

Più dettagliatamente, TRaIT serve a ricostruire la storia evolutiva dei tumori, quindi:

- inferire l'ordine temporale delle alterazioni genomiche (per esempio: mutazioni);
- costruire grafi di progressione tumorale, che rappresentano quali eventi tendono a comparire prima e quali dopo durante l'evoluzione del cancro;

Producendo in output:

- grafi diretti (DAG) di progressione tumorale;
- relazioni di tipo "evento A tende a precedere evento B";
- modelli evolutivi compatibili con selezione darwiniana e accumulo di mutazioni;

Da notare, però, che questi grafi non sono alberi filogenetici classici, ma modelli causali probabilistici della progressione.